

动手学大模型应用开发 · 第 1 节

大模型基础

从下一 Token 预测理解模型怎样学习

主讲：陈思州





- 01 理解输入：前文怎样对应下一 Token**
- 02 理解训练：概率、Loss 与参数更新**
- 03 理解结果：曲线和续写能说明什么**

概念	本课中的含义
字符	我、喜、欢、学、习
Token	本课按字符切分
ID	Token 对应的整数编号

例：临时词表 {我:0, 喜:1, 欢:2}，把“我喜欢”编码成 [0,1,2]。

ID 是查表用的编号，没有大小或相似度含义。真实模型的 Token 未必对应一个汉字。

编码和解码使用同一份词表，保证编号有明确含义。

怎样理解

编码：逐个查“文字对应哪个 ID”。

解码：按 ID 查回原来的文字。

遇到训练词表外字符，要按约定处理。

具体例子

教学词表：我=0，爱=1，学=2

`encode("我爱学") = [0,1,2]`

`decode([0,1,2]) = "我爱学"`

本课按字符切分。换成真实 tokenizer 时，先查看切分结果，再比较长度。

可见的前文	要预测的目标
我	喜
我喜	欢
我喜欢	学
我喜欢学	习

完整文本“我喜欢学习”： $x=[我,喜,欢,学]$ ， $y=[喜,欢,学,习]$ 。

位置 2 输入“欢”时，模型只看“我喜欢”，预测“学”。一次前向可同时计算各位置的预测。

验证集模拟“没有用来更新参数的文本”，必须先隔离文档。



先分文档，再在各自集合内取窗口

验证集泄漏会让成绩看起来更好，却削弱对新文本表现的判断。

正确流程

24 段文档先分为 20 段训练、4 段验证。
词表只用训练文档建立，再分别切窗口。
验证文档不参与反向传播。

反例：先切窗口再随机分组

“我喜欢学习”与“喜欢学习模型”
可能分到两边，重叠内容造成泄漏。
验证成绩变好，不代表泛化更好。

Batch 是一起处理的样本数，上下文长度是每条样本的位置数。

怎样理解

B=2：同时处理两条样本。

T=4：每条样本有四个输入位置。

x 与 y 都是整数矩阵 [B,T]。

具体例子

```
x = [[0, 1, 2, 3],  
      [2, 3, 4, 5]]  
y = [[1, 2, 3, 4],  
      [3, 4, 5, 6]]
```

此例有 $B \times T = 8$ 个预测位置。标签在各自文本中向后错开一位。

把编码和标签错位合在一起，就能得到模型真正使用的训练样本。

构造过程

文字先按词表转换成 ID。

输入 x 去掉最后一个 Token。

目标 y 去掉第一个 Token。

完整例子


原文：“我喜欢学习”

x ：“我喜欢学”

y ：“喜欢学习”

最后一个位置：“学” 预测 “习”。

每个输入位置都要对应正确的下一 Token。位置错一位，模型学到的任务就会改变。



示例分数 [2, 1, 0]; 正确目标是 “看”

模型给出分数 [2,1,0]，softmax 后约为 [0.665,0.245,0.090]。

分数可以任意取实数，概率必须非负且总和为 1。下一页手算这些概率怎样得到。

$$p_i = \frac{\exp(z_i)}{\sum_j \exp(z_j)} = \frac{\exp(z_i - m)}{\sum_j \exp(z_j - m)}$$

z_i : 候选分数 p_i : 候选概率 $m = \max(z)$ $\exp(x) = e^x$

教学算例：候选“学、看、书”，分数为 [2, 1, 0]

候选	分数 z_i	减最大值	取指数	除以总和
学	2	0	1.0000	0.6652
看	1	-1	0.3679	0.2447
书	0	-2	0.1353	0.0900

先减去最大值，避免数值溢出

取指数，再除以总和

所有候选概率相加等于 1

指数总和 ≈ 1.5032 ；“看”的概率 $\approx 0.3679 \div 1.5032 = 0.2447$

角色	谁决定它
正确目标：看	训练数据
最大概率：学	模型输出分数
实际采样：学 / 看 / 书	概率与随机性

同一次预测：训练数据的目标是“看”，最高分是“学”，采样仍可能得到“书”。

训练拿正确目标计算 Loss，生成按解码策略选择 Token。最高分和正确答案是不同概念。



目标概率越高，单位 Loss 越低

目标概率从 0.1 提高到 0.9，负对数损失从约 2.303 降至 0.105。

横轴只改变正确目标的概率。Loss 连续反映预测改善，不要求目标已经排到第一名。

$$\ell = -\ln(p_y)$$

y: 正确目标的下标 p_y : 分配给它的概率 $\ln$: 自然对数

接着用同一例子：正确目标是“看”，不是概率最大的“学”

候选概率: [0.6652, 0.2447, 0.0900]

取出目标概率: $p_y \approx 0.2447$

代入公式: $\ell \approx -\ln(0.2447) \approx 1.4076$

Loss = $-\ln p$ (正确目标)

手算时，取目标对应的概率

PyTorch 的交叉熵直接接收 logits

Python 下标从 0 开始，所以“看”的目标 ID 是 1。

$$L = (\ell_1 + \ell_2 + \dots + \ell_n) / n$$

n: 参与计算的有效位置数 ℓ_t : 第 t 个位置的损失

独立手算练习：两个位置的目标概率分别为 0.5 和 0.25

位置 1: $-\ln(0.5) \approx 0.6931$

位置 2: $-\ln(0.25) \approx 1.3863$

平均: $(0.6931 + 1.3863) \div 2 \approx 1.0397$

每个有效位置都有一个 Loss

把这些 Loss 求平均

错误标签也可能被模型学会

先平均概率再取负对数: $-\ln(0.375) \approx 0.9808$, 结果不同。

观察对象	它能回答什么
训练 Loss	训练数据预测得怎样
验证 Loss	未参与更新的数据预测得怎样
应用任务	是否有依据地完成目标

训练下降、验证上升：优先检查是否过拟合、数据太少或划分不合理。

两条曲线都下降，也只说明当前语料预测改善。仓库任务能否完成，要另做应用评估。

固定正确目标，只提高它的分数，观察概率与 Loss 同时变化。

变化关系

正确目标的相对分数提高。
softmax 后的目标概率上升。
目标概率越高，交叉熵 Loss 越低。

数值对照

原分数 [2,1,0]: $p(\text{看}) \approx 0.2447$
改为 [2,3,0]: $p(\text{看}) \approx 0.7054$
Loss 约从 1.407 降为 0.349。

训练通过调整参数改变 logits，最终提高正确目标的概率。

数据经过的步骤	张量形状
Token ID	[B, T]
Token + 位置嵌入	[B, T, C]
注意力与前馈层	[B, T, C]
词表投影	[B, T, V]

把 $B=2$ 、 $T=6$ 、 $C=48$ 、 $V=20$ 代入：输出形状为 $[2,6,20]$ 。

C 是每个位置的特征宽度， V 是词表大小。最后一维 20 个分数供预测下一个 Token。

嵌入把编号变成可学习的向量，位置嵌入补充顺序信息。

怎样理解

Token 嵌入 $E[id]$: 同一 Token 查同一行。

位置嵌入 $P[t]$: 同一位置查同一行。

模型输入 $h_t = E[id_t] + P[t]$ 。

具体例子

假设某 Token 向量 $[0.2, -0.1]$

位置 0 向量 $[0.0, 0.3]$

相加得到 $[0.2, 0.2]$

同一个字出现在位置 1，会加上另一位置向量。

这是二维教学算例，实际本课宽度为 48。向量各维不能直接命名为“主语”“动词”。

可见范围	0	1	2	3
0	1	0	0	0
1	1	1	0	0
2	1	1	1	0
3	1	1	1	1

行是查询位置，列是被读位置；1 可见，0 屏蔽

行是正在计算的位置，列是它能读取的位置。第 2 行允许读 0、1、2，屏蔽 3。

表中的 0/1 表示可见性。计算时给被屏蔽分数加 $-\infty$ ，softmax 后未来位置权重为 0。

$$\text{Attention}(Q, K, V) = \text{softmax}(QK^T / \sqrt{d_k} + M)V$$

Q: 查询 K: 键 V: 值 d_k : 键维度 M: 掩码 (可见 0 / 未来 $-\infty$)

单个查询的教学算例：缩放后的三个分数为 [2, 1, 9]

第三个是未来位置：加掩码后为 [2, 1, $-\infty$]

softmax 得到权重: [0.7311, 0.2689, 0]

若 $V = [10, 20, 999]$ ，输出约为 12.6894

Q 与 K: 计算对前文的关注程度

因果掩码: 禁止读取未来位置

权重乘 V: 汇总可见位置的信息

$0.7311 \times 10 + 0.2689 \times 20 + 0 \times 999 \approx 12.6894$ (用未舍入值计算)

本课采用预归一化：先整理特征尺度，再计算新信息并加回输入。

```
h = x + attention(norm1(x))  
y = h + ffn(norm2(h))
```

残差：加回输入

$$h = x + F(x)$$

$$x = [1, 2]$$

$$F(x) = [0.2, -0.5]$$

$$h = [1.2, 1.5]$$

输入与增量须形状相同。

前馈：加工每个位置

$$W_2 \text{ GELU}(W_1 u + b_1) + b_2$$

本课宽度 $48 \rightarrow 192 \rightarrow 48$

GELU 提供非线性。

每个位置共用参数，
此处不混合不同位置。

归一化：调整特征尺度

$$\gamma \odot (x - \mu) / \sqrt{(\sigma^2 + \epsilon)} + \beta$$

$$x = [1, 3], \mu = 2, \sigma^2 = 1$$


$$\gamma = 1, \beta = 0, \text{ 忽略小 } \epsilon$$

$$\text{LN}(x) \approx [-1, 1]$$

沿特征维计算均值、方差。

注意力混合位置，前馈层加工特征。残差把新信息加回输入，归一化在各分支之前进行。

让两条输入的前三个位置相同，只替换后面三个位置。



保持不变的条件

两条输入使用同一份模型参数。
前三个位置完全相同。
只替换后面的三个位置。

对照结果

原输入: [1,2,3,4,5,6]

新输入: [1,2,3,9,9,9]

已保存结果:

前三位置最大差异 0。

去掉掩码后, 差异约 0.148。

正确的因果模型中, 同样的前缀应
得到同样的
前缀预测。

把正确掩码与无掩码的情况放在一起，信息泄漏就会变得很直观。

信息范围

正确掩码：只能读取当前位置和前文。

无掩码：每个位置都能读取整段输入。

未来信息因此可能流回前面。

结果差别

正确掩码：前缀最大差异为 0。

无掩码：前缀最大差异约 0.148。

后缀变化影响了前面的输出。

训练时偷看未来标签，Loss 可能很好看。生成时没有未来文本，泄漏带来的优势便不存在。


$$w' = w - \eta \cdot \partial L / \partial w$$

w' : 更新后参数 η : 学习率 $\partial L / \partial w$: 当前位置的梯度

学习率	更新后 w	更新后 Loss
0	0	9
0.1	0.6	5.76
1.2	7.2	17.64

$L = (w - 3)^2$; $w = 0$ 时梯度为 -6 ; $\eta = 0.1$ 时, 新 $w = 0.6$, $Loss = 5.76$ 。

从 $w = 0$ 出发, 最小化 $(w - 3)^2$



输入与目标先对齐，Loss 经反向传播得到梯度，再由优化器更新参数。

模型规模	本次运行
1 层 · 4 个注意力头	39,701 个可训练参数
宽度 48 · 上下文 32	Batch 16
AdamW · 学习率 0.003	240 次更新 · seed 7

本次每步处理 $16 \times 32 = 512$ 个预测位置，共更新 240 次。

4 个头各处理 $48 \div 4 = 12$ 维。配置与曲线属于本次小语料实验，不代表通用模型推荐参数。

相同初始参数，相同数据

只把学习率改为 0

检查参数和固定评估 Loss 是否不变

先猜：参数最大差值和固定评估 Loss 会怎样？



参数今天摸鱼了吗？

同一个模型训练 40 步，
学习率设为 0。

零学习率把“训练循环执行过”和“参数真的更新了”分开。


对照条件

初始权重、数据和训练流程保持一致。
一组使用正常学习率。
另一组只把学习率改为 0。

预期结果

正常组：参数和固定评估 Loss 可以变化。
零学习率组：参数保持不变。
固定样本避免把 Batch 波动当作学习。

固定评估样本能隔离抽样差异，避免把 Batch 波动误认为参数学习。



小语料真实运行结果；不代表通用任务能力

先沿横轴看更新步数，再分别读训练与验证曲线。两者属于同一保存的训练运行。

曲线下降支持“小语料预测变好”。还需结合下一页续写，不能推出事实可靠或已具备 Agent 能力。

训练前（节选）

学习错任也参序住到据务结，较
程练想天记例录记条验条

训练后（节选）

学习不只是记住答案，也要检查
过程。数据太少时，模型可能记
住例子

同一前缀“学习”，训练后出现更连贯的片段，也复现了小语料中的表达。

连贯性改善与记忆训练文本可以同时发生。要判断泛化，需保留训练外文本和更多前缀对照。

$$p_i(T) = \text{softmax}(z/T)_i = \exp(z_i/T) / \sum_j \exp(z_j/T)$$

$T > 0$: 生成温度; 先把分数除以 T , 再转换为概率。

生成温度	对概率分布的影响
$0 < T < 1$	更集中于高分候选
$T = 1$	保持原分布
$T > 1$	分布更平缓

同一组 $[2, 1, 0]$: $T = 0.5$ 时概率 $\approx [0.867, 0.117, 0.016]$; $T = 1$ 时 $\approx [0.665, 0.245, 0.090]$ 。

温度改变采样分布, 不改变模型参数

一个结论应能指向曲线、样例或可复现的对照。

怎样理解

观察：训练、验证 Loss 都下降。

解释：当前样本上的预测更好。

边界：语料小，续写可能记住原文。

具体例子

可支持：“这次训练使续写更连贯。”

证据：相同前缀的训练前后样例。

不能支持：模型会可靠回答任何问题。

下一轮只改学习率或步数之一，保存种子、数据划分与生成设置，才能比较。

曲线、续写和反例放在一起，才能判断模型学到了什么。

三类证据

曲线：下一 Token 预测是否改善。

续写：数值变化是否对应到文本。

反例：训练外输入是否仍会失败。

结论边界

可以支持：模型学到小语料中的局部规律。

仍需保留：重复、记忆和不稳定输出。

不能支持：模型已经具备通用问答能力。

结论的范围不能超过证据。改善和失败都应该保留。

环节	我们如何处理
预训练	本节完成最小训练
指令学习 / 偏好优化	认识后训练的位置
应用调用	后续统一使用 DeepSeek

预训练学习文本分布，指令学习用示范任务引导响应，偏好优化进一步影响响应选择。

本节只实现最小的下一 Token 训练。后续直接调用现成模型，把注意力放到应用的工具与运行机制。

后续保留“模型输入与输出”的接口，把执行工作交给应用。

怎样理解

模型输入：任务、已有消息和工具声明。

模型输出：文字，或名称与参数。

应用读取输出，校验后调用函数。

具体例子

用户问：“配置在哪？”

模型提出 `read_file("main.py")`。

Python 读取文件，回传内容。

模型结合内容回答，并引用位置。

模型提出行动，程序执行行动。第二节将把这条连接真正写出来。

- 1 数据：把前文组织成下一 Token 任务
- 2 模型：用因果注意力读取可见前文
- 3 训练：用 Loss 与梯度更新参数
- 4 验证：用对照和真实结果解释变化



自检：学习率为 0，哪些结果应保持不变？