Datawhale

动手学大模型应用开发 · 第 7 节

智能体评估与对照实验

用任务证据判断系统是否真正完成目标



主讲：陈思州

本节学习路线

Datawhale

理论主线 • 从一次看起来成功，到可复现的任务证据

评估不是给一个回答打总分，而是说明任务、环境、证据、判断和不确定性。

01 评估对象

任务、试验、轨迹与结果

02 评分证据

规则、模型与人工判断

03 重复汇总

多次试验与稳定性指标

04 对照改进

控制变量、切片与失败分析

先固定任务和成功标准，再谈模型或系统是否更好。

一次完整评估包含六个对象

Datawhale

对象模型 • 评估程序管理试验，被评系统只负责尝试完成任务

同一个任务可以有多次试验；同一次试验可以同时保留过程和最终结果。

Evaluation	固定条件，收集证据，应用评分并汇总

01	Task 与 Trial	固定任务；从规定状态独立尝试
02	Trace	模型、工具与状态转移
03	Outcome	最终答案、环境和产物
04	评分与汇总	判断明确命题；按任务和版本汇总

不要用一条总分同时代替任务定义、过程证据和结果判断。

任务契约要固定输入、环境、目标与约束

Datawhale

任务契约 • 把“完成任务”写成可以检查的状态变化

成功标准既要描述交付物，也要描述不能破坏的约束。

Task Contract 同一任务的每次试验共享固定条件

01 输入

用户问题与可见说明

02 初始环境

资料、文件、账户与版本

03 成功条件

最终答案、环境状态与证据

04 允许边界

工具、权限、预算与禁止副作用

任务定义不清，后面的评分精度再高也不能回答系统是否成功。

评估环境要控制保真度与可重复性

Datawhale

环境设计 • 可重复性与真实感需要同时说明

环境噪声会制造相关失败，也可能让后一次 Trial 继承前一次留下的答案。

可比较的 Trial 相同契约从可重建起点独立运行

01	初始状态	固定文件、数据库、账户、时间和任务版本
02	工具与数据	记录接口、资料快照和允许访问的外部系统
03	资源条件	控制超时、并发、网络、算力和速率限制
04	隔离与清理	每次清除缓存、临时产物和上次运行副作用

环境条件不受控时，分数变化不能只归因于 Agent。

每个 Trial 都要从规定初始状态独立开始

Datawhale

试验语义 · 重复次数不是同一条轨迹中的多轮调用

独立试验允许观察不稳定性，也避免前一次运行偷偷改变下一次的起点。

01	**重置环境**	回到任务规定的初始状态
02	**固定版本**	模型、提示、工具、资料与代码
03	**独立执行**	新 trial_id，单独记录用量
04	**保存证据**	轨迹、最终状态、产物与错误
05	**应用评分**	按同一成功标准判断

可比较的重复，首先要求起点和版本可说明。

Trace 与 Outcome 回答不同问题

Datawhale

A

Trace：过程证据

模型请求、工具调用、观察、状态转移、错误与耗时。用于定位原因，但过程漂亮不代表任务成功。

边界

B

Outcome：结果证据

最终答案、环境状态、文件、外部记录与可回查产物。用于判断任务是否完成，但结果通过也不代表过程安全。

评分器应围绕可解释命题组合

Datawhale

评分组合 · 不同证据使用不同判断方法

评分器输出是一项测量，不是不可质疑的真相。

Task Success　　多个必要条件共同构成任务通过

01 结构与格式

解析、Schema、类型与必填字段

02 任务事实

参考答案、规则或语义量表

03 环境状态

文件、测试、数据库与外部结果

04 证据支持

引用存在、覆盖且真正支持结论

先写评分器能证明什么，再决定怎样组合为任务成功。

评估集还要治理来源、难度与泄漏

Datawhale

数据集治理 · 分数可信之前，任务本身要可信

来源、覆盖和版本不透明时，高分无法说明系统在真实任务上更可靠。

可维护的评估集　　任务分布、答案、环境版本和变更记录共同受控

01 任务来源

真实失败、人工设计、用户日志或公开基准，并记录采样偏差

02 难度分层

按步骤长度、工具数量、状态依赖和安全约束切片

03 泄漏防范

隔离公开答案、训练语料和测试凭据，检查异常高分

04 持续维护

环境、工具和策略变化后复核任务、验证器与基线

评估集要能解释覆盖了什么，也要能说明没有覆盖什么。

规则评分器精确，但只覆盖被编码的条件

Datawhale

A

适合规则检查

字段、类型、文件、测试、数值范围、确定引用位置。相同输入应得到稳定结果。

边界

B

不能自动推出

讲解是否充分、引用是否支持整段结论、未编码事实是否正确、任务外风险是否可接受。

模型评分必须经过量表、校准与抽查

Datawhale

模型评分闭环 · 评分提示本身也需要评估

模型能扩展开放语义判断，但会继承提示敏感、位置偏好和自洽性问题。

01	**明确量表**	定义等级、证据和失败边界
02	**隔离文本**	被评内容不能覆盖评分指令
03	**建立样例**	正确、错误、矛盾与边界案例
04	**比较一致性**	与人工标签及重复判断对照
05	**人工抽查**	复核分歧、异常与高风险结果

模型评分器是待校准的测量工具，不是免复核的事实来源。

评分分歧本身也是评估结果

Datawhale

评分校准 · 先解释分歧，再决定怎样汇总

一个平均分会掩盖评分器是否在检查同一件事。

分歧样本池 保留任务、证据、判断、理由和最终裁决

01 规则与模型冲突

检查未编码质量要求或模型误读

02 评审不一致

核对量表、样例和专业知识差异

03 证据不足

允许无法判断，不强迫评分器猜测

04 量表边界

把反复争议样本加入校准集并修订定义

分歧不是噪声，它指出评估系统尚未对齐的位置。

失败归因要定位第一个偏离证据的步骤

Datawhale

失败诊断 • 从结果倒查首个可观察偏离

后续错误通常是早期偏离的连锁反应，不能把最后一次报错当成根因。

01	**还原任务契约**	确认输入、初始环境、目标、约束和成功条件
02	**逐步读取轨迹**	对齐模型陈述、工具返回、环境状态和外部副作用
03	**定位首次偏离**	找出第一处与事实、约束或可接受动作集合不一致的位置
04	**归属责任层**	区分模型、上下文、工具、Harness、环境或评分器问题
05	**生成回归任务**	冻结首错前状态，验证修复能否改变下一步可观察行动

先修复首个错误，再用端到端任务检查连锁影响。

不同基准测量不同任务能力

Datawhale

基准	任务与环境	主要结果证据	课程借鉴
BFCL	结构化函数与工具调用	函数选择、参数和值的匹配	单步协议正确性要和完整任务成功分开
GAIA	真实世界通用助手问题	最终答案与多步信息使用	任务需要推理、检索和工具协作
SWE-bench	真实仓库 issue 修复	代码补丁与测试状态	不能用文字自述代替环境结果
tau-bench	工具与用户交互任务	环境状态、策略约束与稳定性	结果正确之外还要检查交互边界

BFCL 测例：工具选择与参数结构

Datawhale

课程化示意测例 • 复现 BFCL 的输入与判分结构

测试目标是函数调用协议，不要求 Agent 完成一个长程业务任务。

用户请求

查询上海和悉尼当前天气，单位使用摄氏度

1

2

候选函数

当前天气、天气预报、地理编码

期望调用

两次当前天气调用，城市与单位参数正确

3

4

评分器

比较调用结构，必要时执行函数验证结果

BFCL 把“会不会调用工具”拆成函数选择、参数结构和可执行结果。

GAIA 测例：找到并规范化唯一答案

Datawhale

论文示例 • Level 1 仍要求真实检索与字段判断

问题对人类并不复杂，难点在于找到正确来源并输出无歧义答案。

01	任务	查找指定临床试验的实际入组人数
02	检索	定位研究与 NIH 页面，排除相似试验
03	核对	选择 Actual Enrollment，不混用计划人数
04	判分	最终答案为 90，按数值规范化匹配

GAIA 测的是多步获取信息后能否交付唯一、简短、可核对的答案。

SWE-bench 测例：补丁必须通过两组测试

Datawhale

真实仓库任务 · 文字说明不能代替环境中的测试结果

Agent 只看到问题和代码库，隐藏测试在运行结束后判断补丁。

输入

Issue 文本与固定版本代码仓库

1

2

Agent 行动

定位实现，编辑文件，生成可应用补丁

3

FAIL_TO_PASS

原先失败的目标测试现在必须通过

4

PASS_TO_PASS

原先通过的相关测试仍然必须通过

SWE-bench 同时检查问题是否修复，以及补丁是否引入回归。

tau-bench 测例：结果正确还要遵守业务策略

Datawhale

论文示例 • 工具、用户与政策共同决定成功

业务任务不能只看最后订到了什么，还要检查 Agent 是否越权或违反规则。

01	用户目标	请求修改一张基础经济舱机票
02	政策判断	该票种不能直接改签，需要说明限制
03	交互与工具	确认替代方案，再执行允许的取消与重订
04	判分	比较数据库终态、策略遵循和重复成功

tau-bench 测的是对话过程中持续遵守策略并把环境推进到正确状态。

重复试验用来观察系统不稳定性

Datawhale

重复与汇总 · 先保留试验级事实，再形成任务级和系统级指标

一个任务重复很多次，不应因此在总体分数中自动获得更大权重。

01 任务内重复

观察同一任务的波动

02 任务间差异

按类别与难度查看分布

多次 Trial

独立起点、固定版本、完整保存成功和失败

03 版本差异

明确模型、提示、工具与代码版本

04 缺失与失败

超时、错误和未完成进入分母

完整记录失败和缺失，才有资格讨论稳定性。

pass@k 与 pass^k 回答相反的可靠性问题

Datawhale

pass@k：至少一次成功,k 次独立尝试中至少成功一次。适合允许多个候选的任务。

pass^k：每次都成功,所有独立尝试都成功。适合每次执行都必须可靠的任务。



两次机会，怎么算 OK?

四次记录：成功、成功、失败、失败。任选两次。

列组合：至少一次成功与两次都成功，各有几组?

有限样本需要表达结果的不确定性

Datawhale

统计解释 • 把样本波动与真实差异分开

分数只有和样本量、重复次数、切片与决策阈值一起报告才可用于比较。

01 重复次数

同一条件下独立 Trial 的数量和随机设置

02 切片样本

每类任务的样本量与任务分布是否代表目标场景

可解释的差异

当前证据支持多大的改进，以及结论有多稳定

03 区间估计

用置信区间或重采样范围表达分数不确定性

04 实际阈值

改进是否足以抵消成本、延迟、风险和迁移工作

不要把小样本中的一两个百分点直接解释成稳定提升。

对照实验一次只改变一个解释变量

Datawhale

控制变量 • 改动可解释，比一次堆叠多项升级更有学习价值

完整对照要同时保留改善、退化、无变化和缺失试验。

1. **冻结任务集**

   同一输入、初始状态与成功条件

2. **冻结环境**

   同一资料、工具、预算与评分器

3. **唯一改动**

   明确本轮只改变哪一项

4. **配对执行**

   同一任务比较旧版与新版

5. **比较差异**

   总体、逐题、成本与失败层

无法指出唯一改动，就无法把结果差异解释为该改动的效果。

配对差异比两个平均分更能解释改动

Datawhale

受控比较 • 每个任务都保留 A 与 B 的对应结果

总体分数只能显示净变化，无法说明收益来自哪些任务，也无法显示被抵消的回归。

任务级配对　　同一任务、同一环境、同一评分器，只改变一个因素

01 保持成功

确认改动没有破坏已有能力

02 由败转胜

形成改进证据，并回查首次正确决策

03 由胜转败

形成回归清单，定位被破坏的边界

04 保持失败

说明改动未命中根因或任务仍超出能力

先读任务级配对变化，再解释总体分数。

汇总分数之外还要看切片与失败层

Datawhale

诊断结构 • 指标发现变化，失败分类解释变化

同样的失败结果，可能来自不同层次，修复方法也完全不同。

Failure Analysis　把试验证据映射到可行动的失败层

01 输入理解

目标、约束或上下文选择错误

02 决策规划

下一步选择、顺序或停止判断错误

03 工具执行

参数、权限、环境或外部服务失败

04 结果验收

未核对事实、环境或交付条件

失败标签要能指向下一次可验证的改动，而不是只写“模型不够好”。

成本评估要覆盖模型、工具与运行开销

Datawhale

效率证据 • 单次 Token 价格只是成本的一部分

多轮调用、工具等待和失败恢复会让 Agent 成本随轨迹长度非线性增长。

端到端任务成本 在相同成功条件下统计完成一次任务的全部资源

01	**模型调用**	输入、输出、推理 Token，模型轮次和上下文增长
02	**工具与检索**	数据库、搜索、浏览器、第三方 API 和数据传输
03	**运行环境**	计算、存储、沙箱、监控、队列和等待时间
04	**失败与人工**	重试、回滚、人工复核、事故处理和不可逆损失

比较方案时同时报告成功率、端到端延迟和每个成功任务的完整成本。

评估闭环从失败证据回到下一项改动

Datawhale

迭代闭环 • 评估的产物不是分数，而是下一轮可验证假设

每一轮保留任务、版本、试验、评分和诊断，才能比较长期变化。

01	固定版本	任务集、系统、环境和评分器
02	运行试验	独立执行并保留全部结果
03	应用评分	任务级判断与多次汇总
04	分析失败	切片、轨迹、结果与边界
05	提出改动	一次只改变一项并建立新版本

旧试验不覆盖，失败不删除，改动才能被证据解释。

本节知识结构

Datawhale

1. **任务、环境、轨迹、结果和评分器共同决定一个分数的含义。**
2. 环境保真度与评估集治理决定任务是否具有代表性。
3. 规则、模型与人工评分需要分工，并保留分歧证据。
4. 对照实验比较同一任务的配对差异，再结合成本与失败层决策。



参考文献与延伸阅读

Datawhale

本节关于 Agent 评估对象、代表性基准、重复可靠性与模型评分主要参考以下资料。

[1] Anthropic

Demystifying Evals for AI Agents

anthropic.com/engineering/demystifying-evals-for-ai-agents

[2] Patil, Shishir G., et al.

The Berkeley Function Calling Leaderboard

ICML 2025 · gorilla.cs.berkeley.edu/leaderboard

[3] Mialon, Grégoire, et al.

GAIA: A Benchmark for General AI Assistants

arXiv:2311.12983

[4] Jimenez, Carlos E., et al.

SWE-bench: Can Language Models Resolve Real-World GitHub Issues?

ICLR 2024 · arXiv:2310.06770

[5] Yao, Shunyu, et al.

τ-bench: A Benchmark for Tool-Agent-User Interaction in Real-World Domains

arXiv:2406.12045